UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

ACREDITACIÓN INSTITUCIONAL MULTICAMPUS
DE ALTA CALIDAD POR 8 AÑOS
Resolución 014525 del 28 de julio de 2022

CUMBRE DE DIVISIONES

ARQUITECTURA E INGENIERÍAS Y CIENCIAS JURÍDICAS

CONGRESO INTERDISCIPLINARIO

5 y 6 de noviembre de 2026

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERÍAS Y CIENCIAS JURÍDICAS

UNIVERSIDAD DEL QUINDÍO

Taller:
Fundamentos Deeplearning y Despliegue en Sistemas embebidos

Jorge Iván Marín H, PhD

Universidad del Quindío

IEEE Senior Member

Chair Capítulo Colombiano IEEE CASS

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

CUMBRE DIVISIONES DE ARQUITECTURA E INGENIERÍAS Y CIENCIAS JURÍDICAS

UNIVERSIDAD DEL QUINDÍO

Agenda

- Principios básicos de reconocimiento de patrones
- Redes neuronales estándar: Perceptrón multicapa (MLP)
- Redes neuronales convolucionales (CNN)
- Creación de un modelo desde cero
- Entrenamiento por transferencia de aprendizaje
- Implementación en sistemas embebidos

Fundamentos básicos de deeplearning

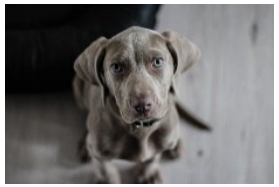
UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

CUMBRE DIVISIONES DE ARQUITECTURA E INGENIERÍAS Y CIENCIAS JURÍDICAS

UNIVERSIDAD DEL QUINDÍO

Sistema típico de reconocimiento de patrones





Reducción de dimensionalidad

100 x 100 x 3

70

2

Preprocesamiento

Extracción de características (*Feature extraction*)

Clasificador

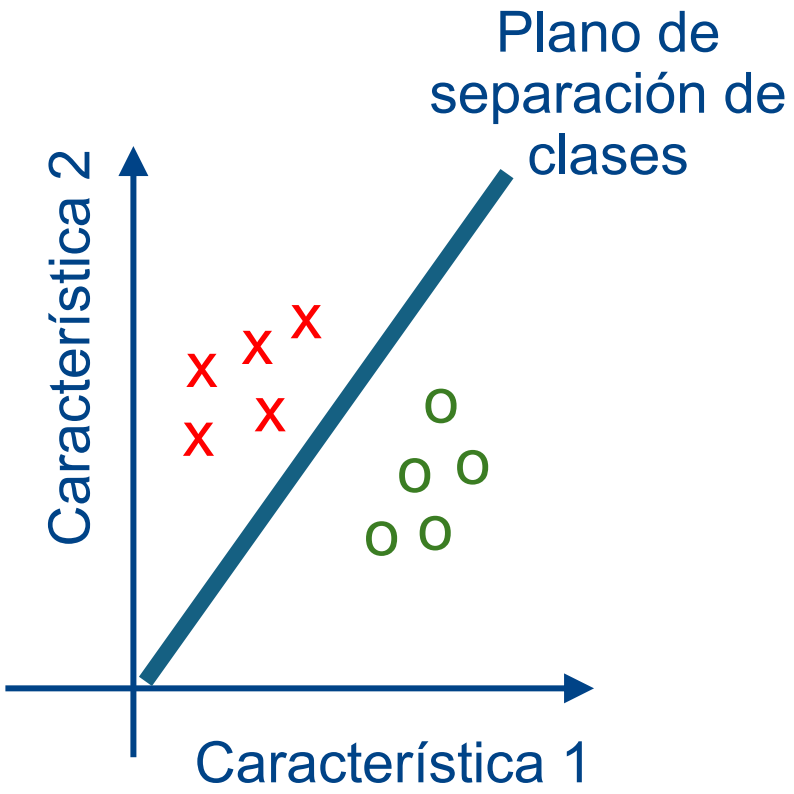
Gato

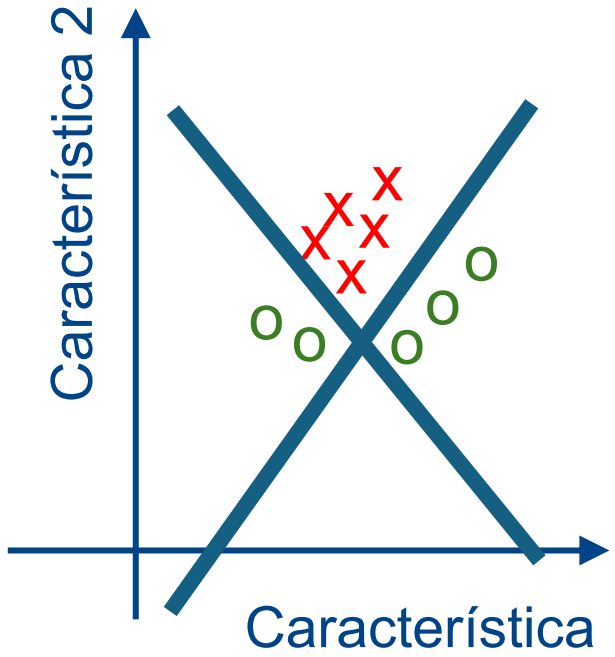
Perro

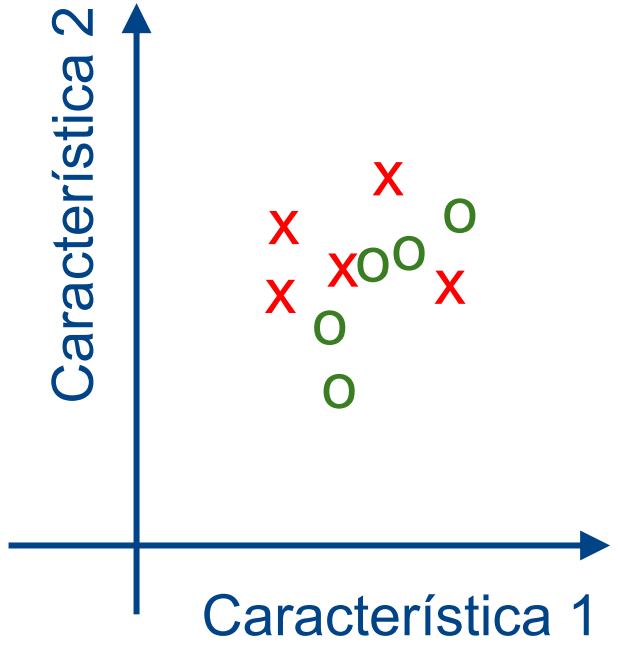
Ajuste de tamaño / pre-filtrado / espacio de color

Filtros / Transformadas / Mediciones estadísticas

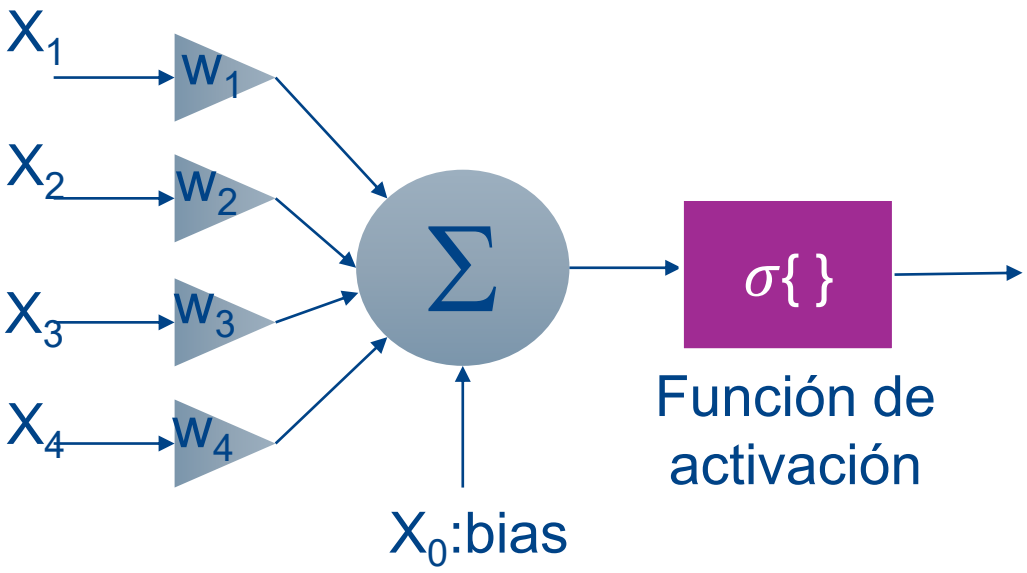
¿Cómo funciona un clasificador?

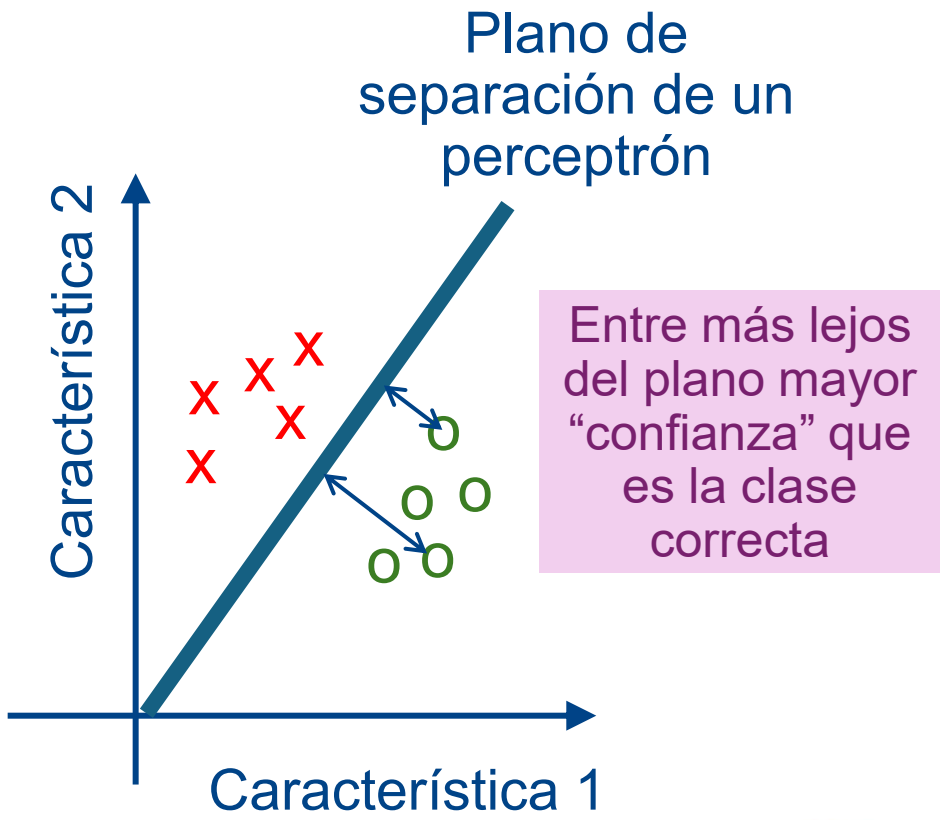






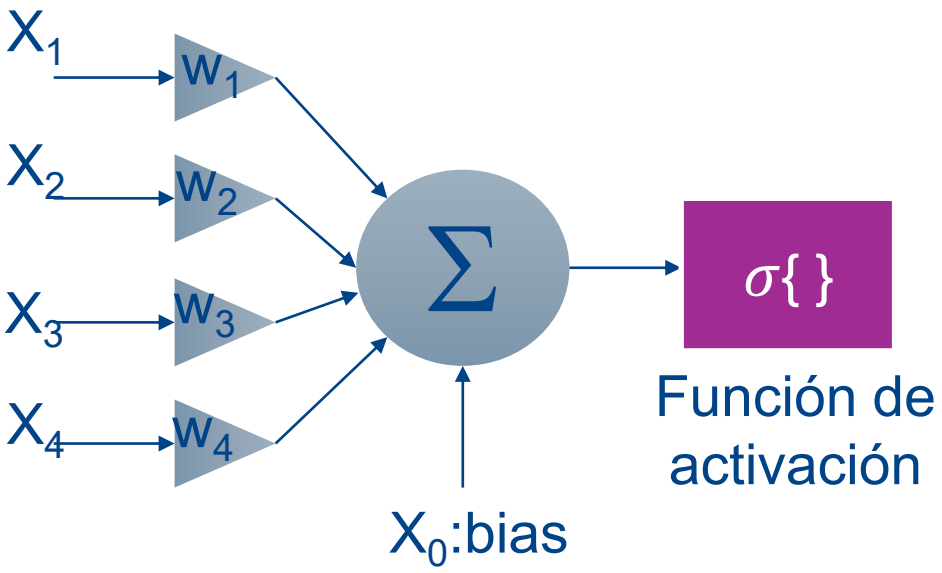
Perceptrón (una neurona)





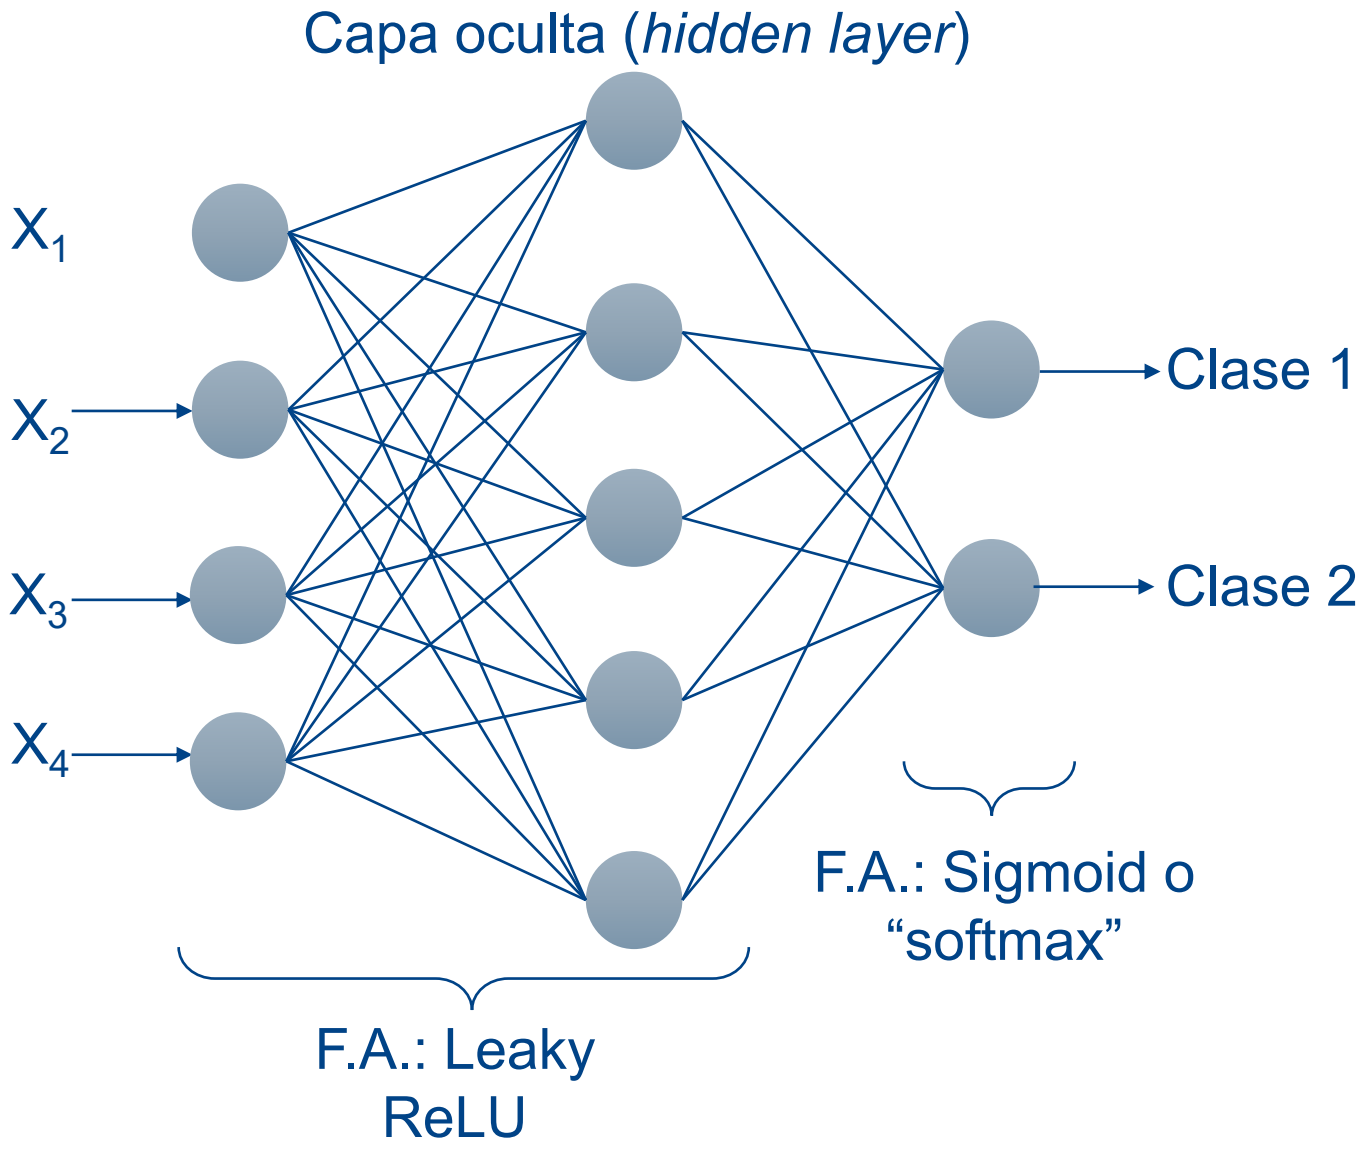
Entre más lejos del plano mayor "confianza" que es la clase correcta

Perceptrón (una neurona)



Función de activación	Respuesta
Tansig	
Sigmoid	
ReLU	
Leaky ReLU	

Perceptrón Multicapa (MLP)



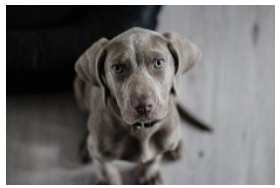
¿Cómo se entrenan?

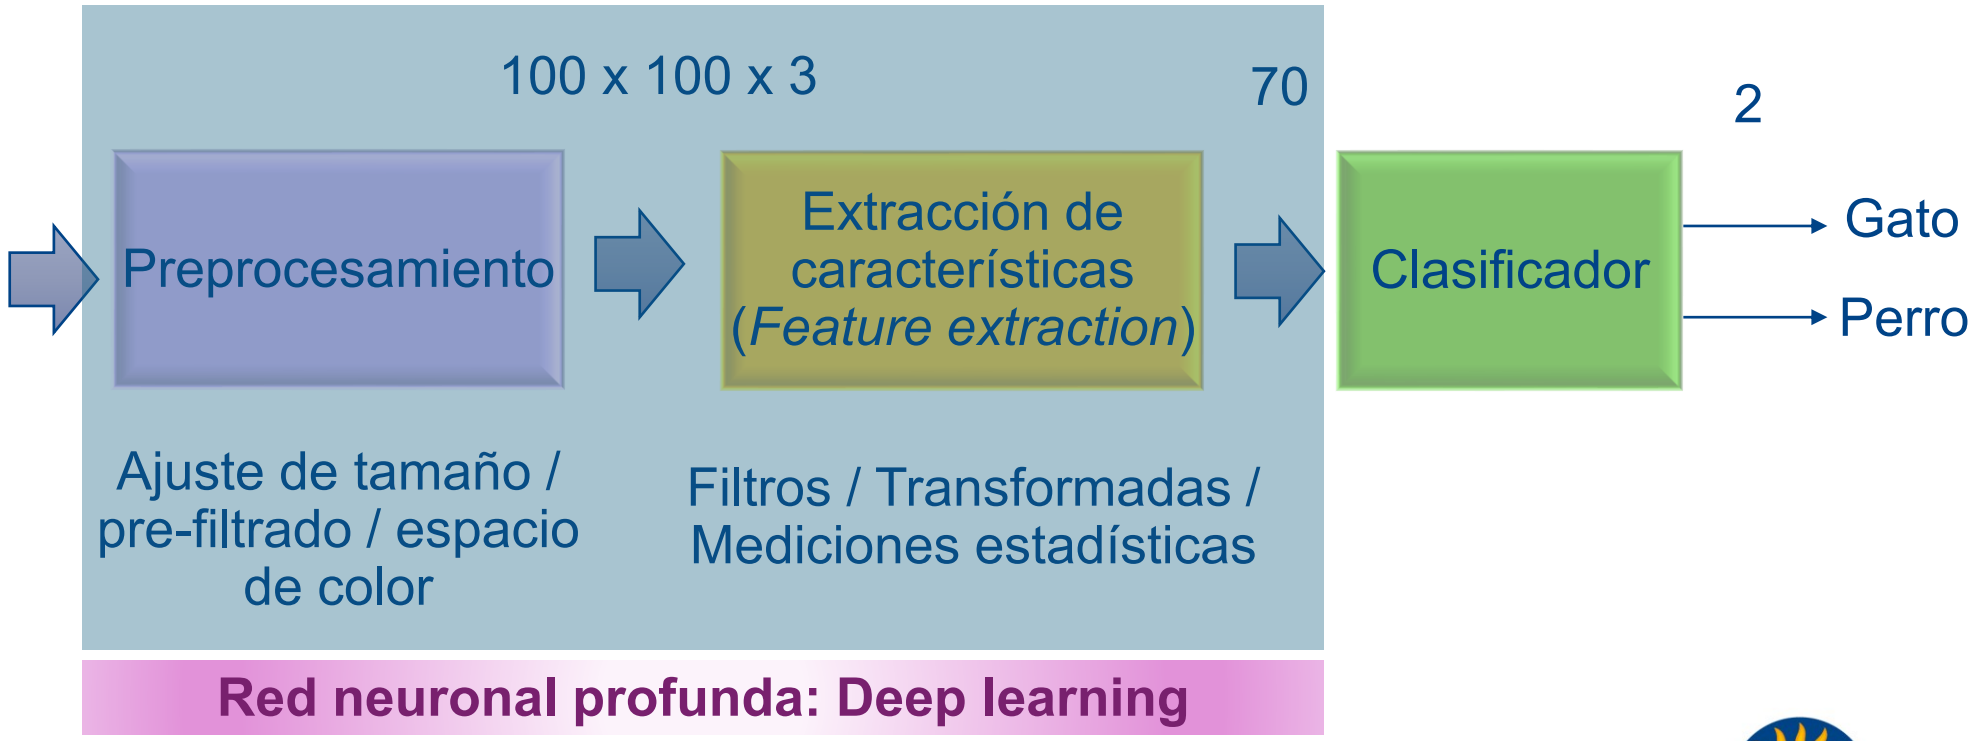
- Aprendizaje supervisado
- Solo una salida activa por clase
- Capa de salida usa sigmoid o "softmax" (aproximación a una probabilidad)
- Algoritmo backpropagation

Redes neuronales convolucionales (CNN)

Se reemplaza por filtros lineales y no lineales entrenados a manera de una red neuronal



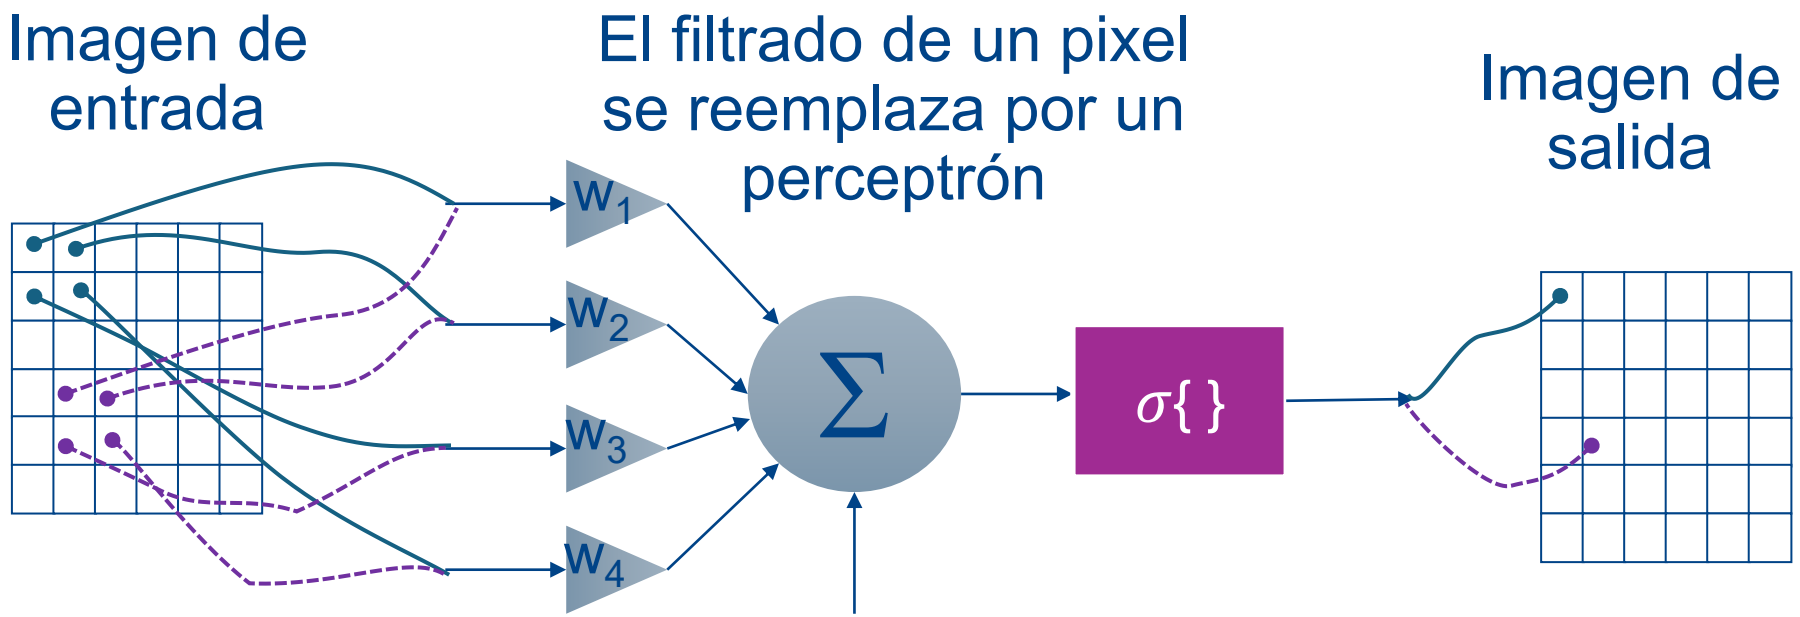




Etiquetado manual de patrones para entrenar IA



Redes neuronales convolucionales (CNN)

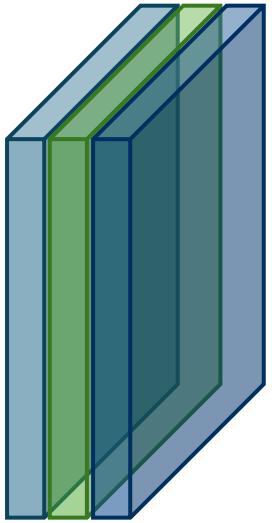


Redes neuronales convolucionales (CNN)

Convolutional Layer

Imagen de entrada (RGB)

100 x 100 x 3



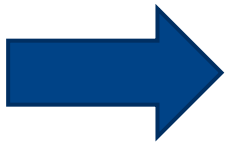
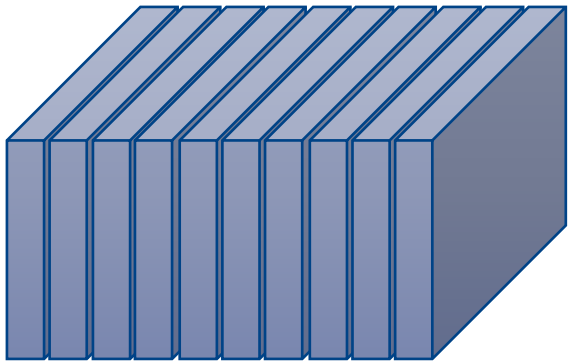


Imagen de salida (*Feature map*)

30 x 30 x 10



Otro tipo de capas:

- **Max-pooling**: Retorna el valor máximo dentro de la máscara del filtro
- **Dropout**: Durante entrenamiento, un % de neuronas no se entrenan

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

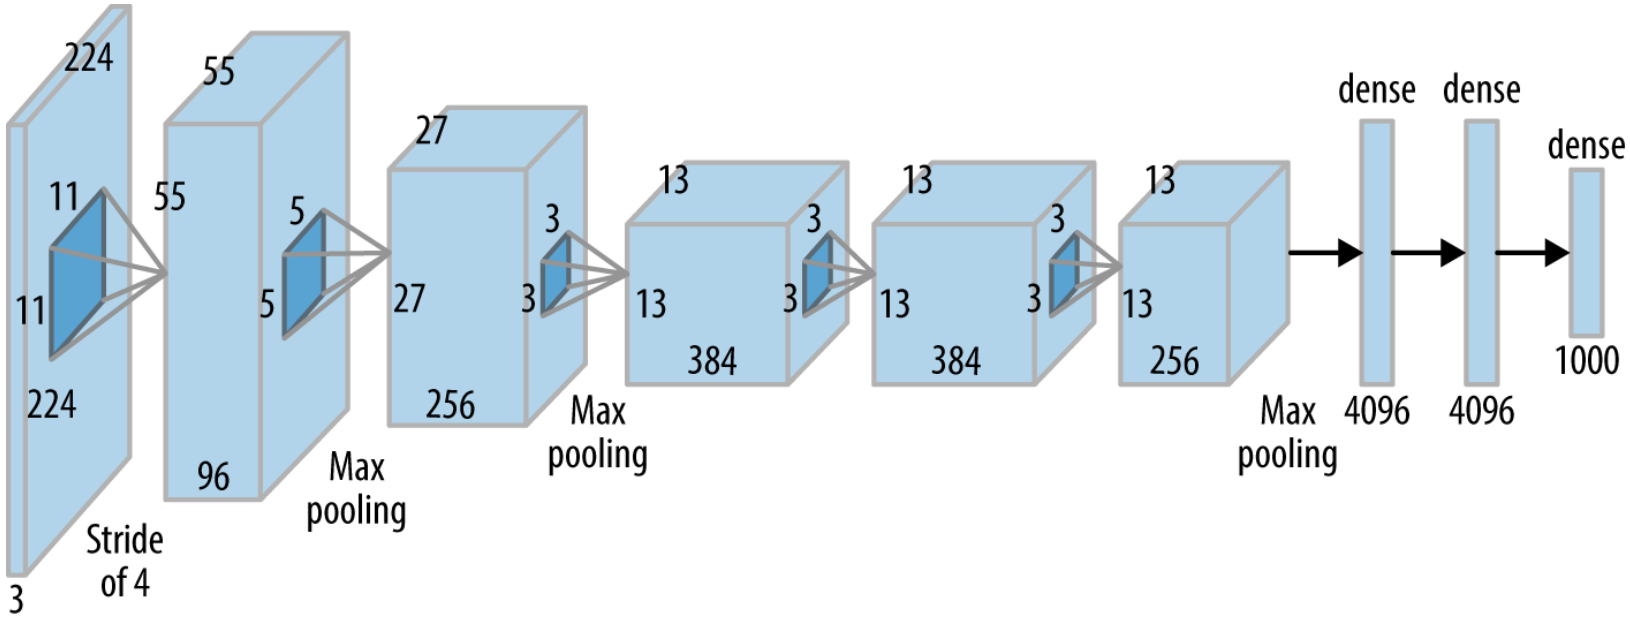
UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Modelos Pre-entrenados

- **AlexNet (2012)**:
  - Primera CNN para base de datos ImageNet (Error 15%)
  - 11x11, 5x5, 3x3 Conv, Maxpool, dropout, dense (ó MLP)
  - 60 millones de parámetros (2 GPUs x 6 días)

ImageNet

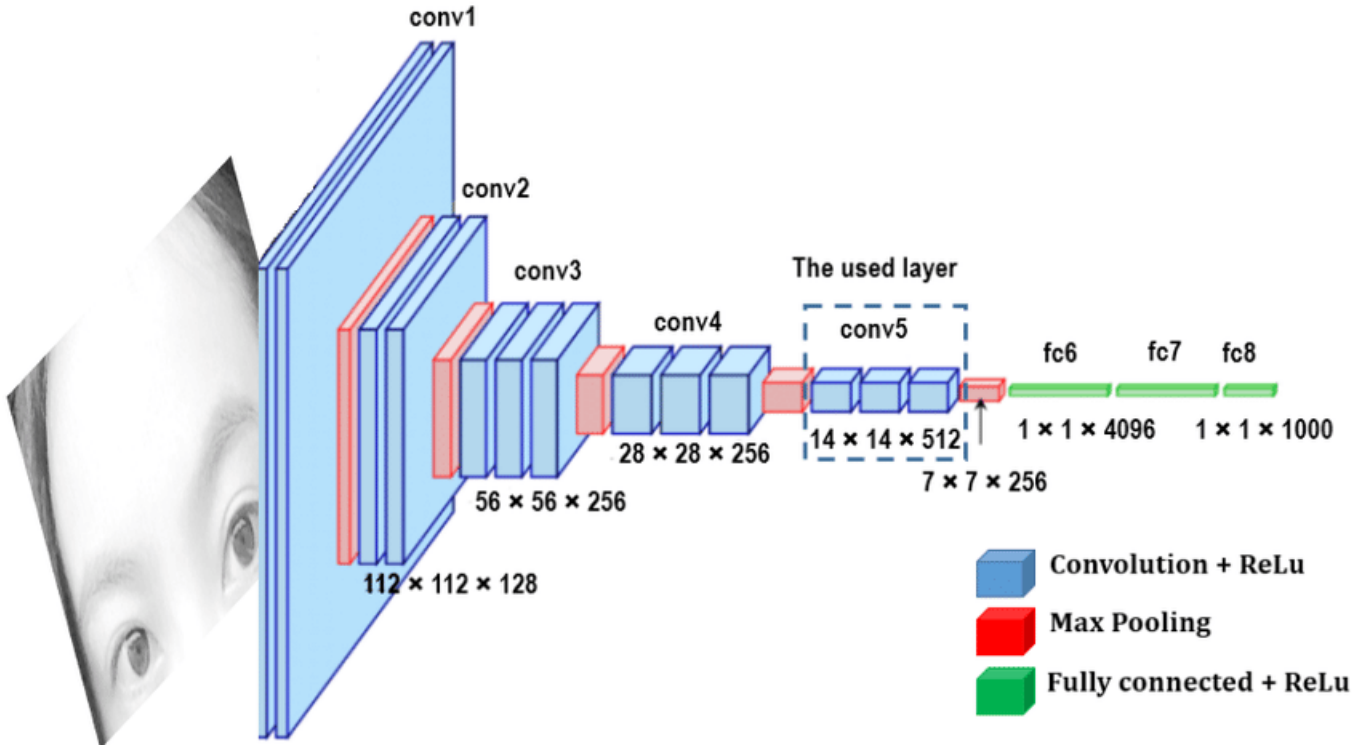
- 14 millones de imágenes
- 20,000 categorías
- Imágenes 224 x 224 x 3



UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Modelos Pre-entrenados

- **VGG (2015)**
  - Similar a AlexNet pero con Conv. 3x3
  - Error con ImageNet: 8%
  - 138 millones de parámetros (4 GPUs x 2-3 semanas)



UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

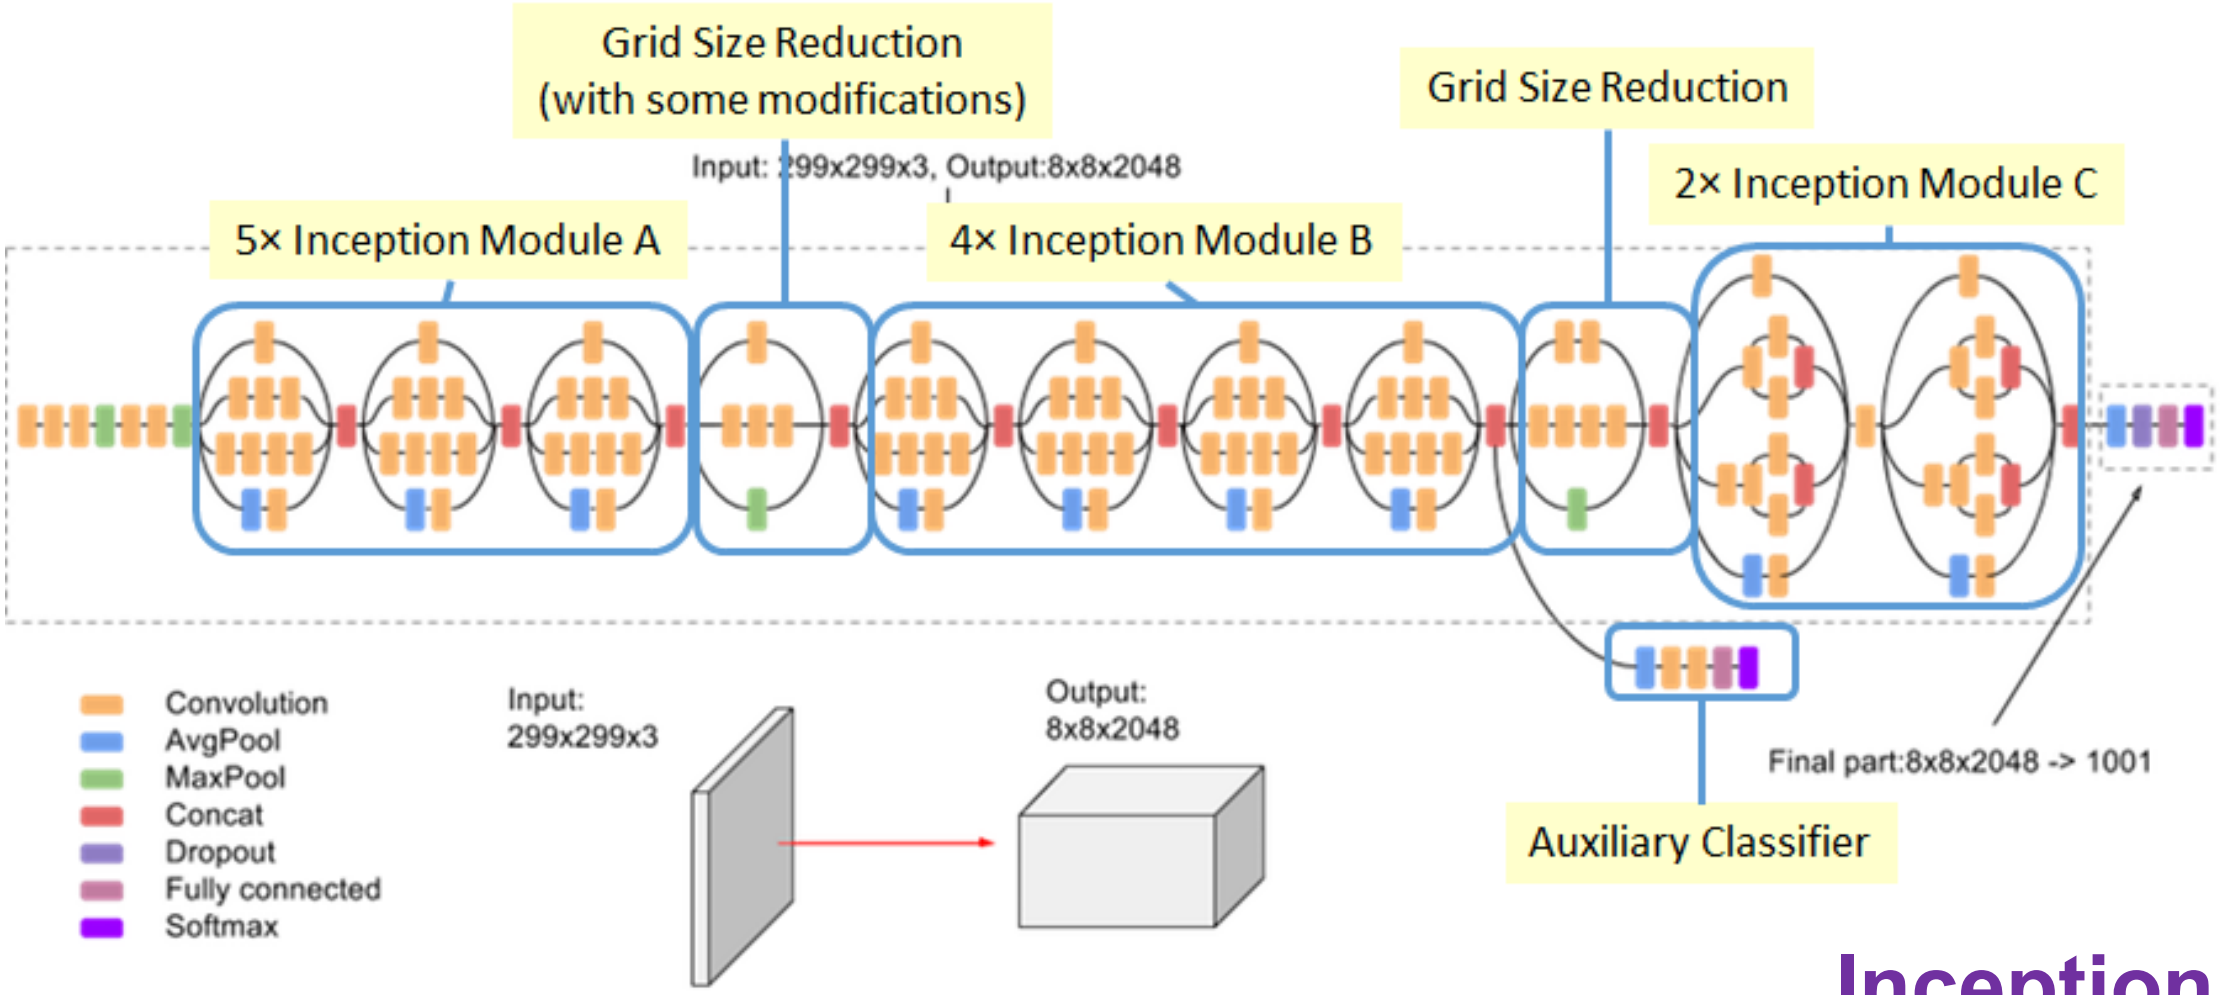
Modelos Pre-entrenados

- **Inception V3 (2015)**:
  - Error con ImageNet: 5.6%
  - Usa bloque inception
  - 25 millones de parámetros (8 GPUs x 2 semanas)

- **ResNet (2015)**:
  - Error con ImageNet: 4.5%
  - Usa conexiones residuales – 152 capas
  - 60 millones de parámetros (8 GPUs x 2-3 semanas)

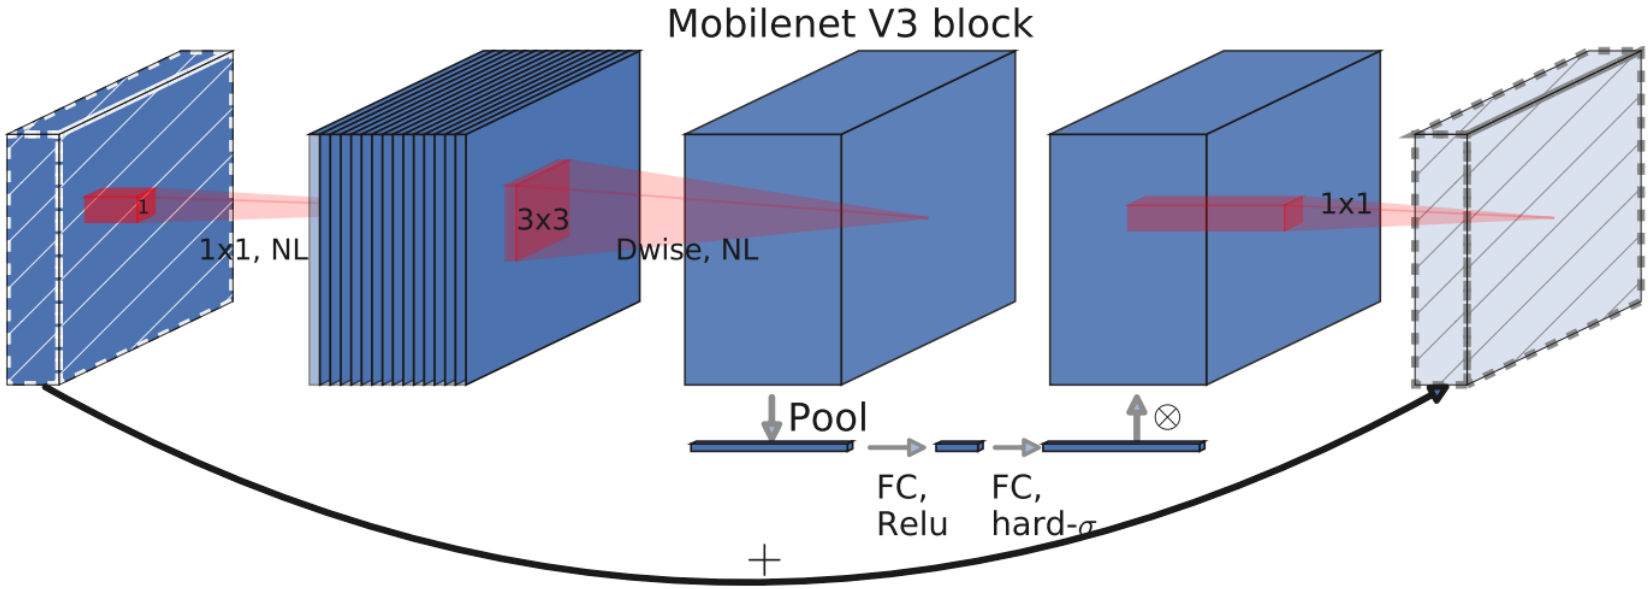
CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS
UNIVERSIDAD DEL QUINDÍO
UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Modelos Pre-entrenados



Inception V3

Modelos Pre-entrenados

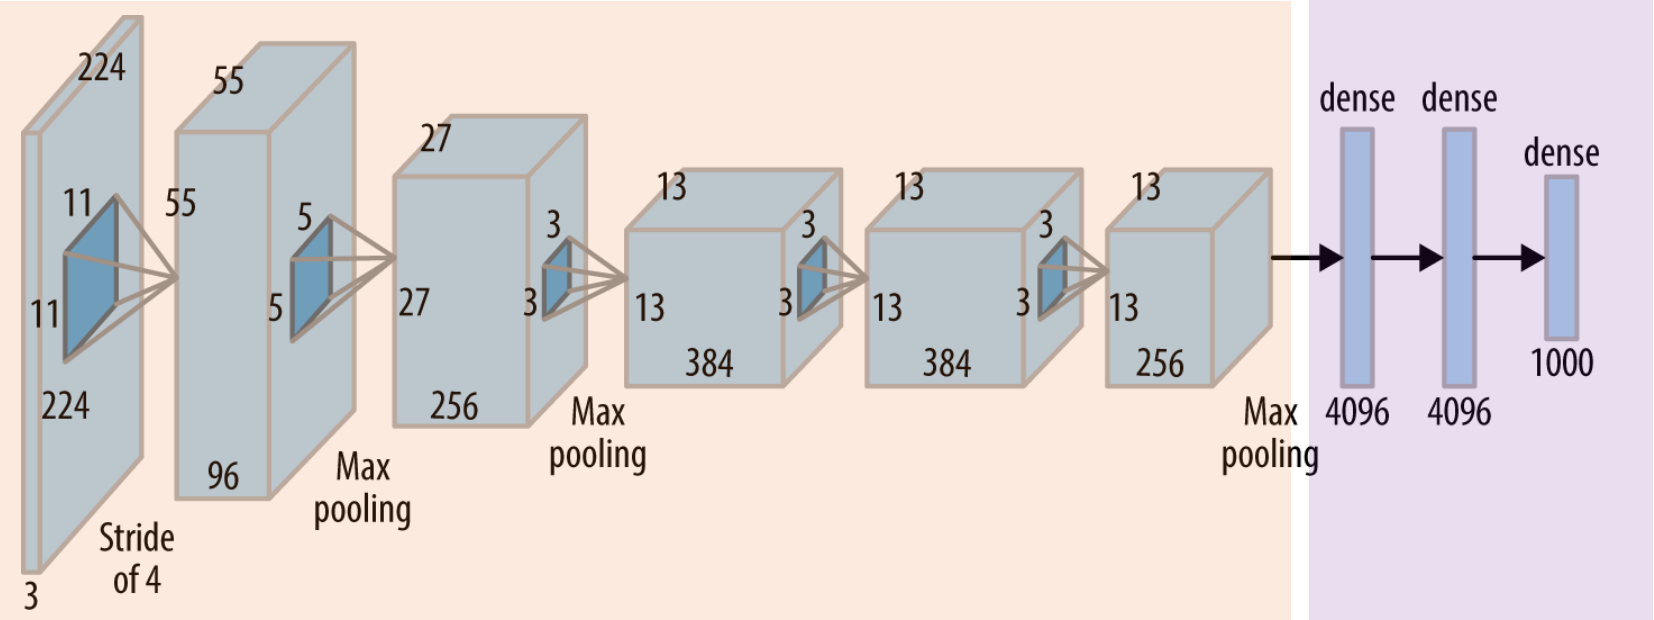


MobileNet

- Preferido para sistemas embebidos
- Usa capas deepwise convolution y residuals
- MobileNet v2 (3.5M)
- MobileNet v3 large (5.4M)
- MobileNet v3 small (2.5M)

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Entrenamiento por Transferencia de Aprendizaje



- Usar modelo pre-entrenado
- Usar las mismas capas de extracción
- Solamente entrenar las capas del clasificador.

Capas relacionadas con extracción de características

Capas relacionadas con la clasificación

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Entrenamiento por Transferencia de Aprendizaje

	Conjunto de entrenamiento similar a ImageNet	Conjunto de entrenamiento diferente a ImageNet
Conjunto de entrenamiento pequeño	Entrenar últimas capas dense (MLP)	Conseguir más datos de entrenamiento
Conjunto de entrenamiento grande	Mejorar el entrenamiento de las capas más profundas	Entrenar desde cero

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Despliegue de modelos

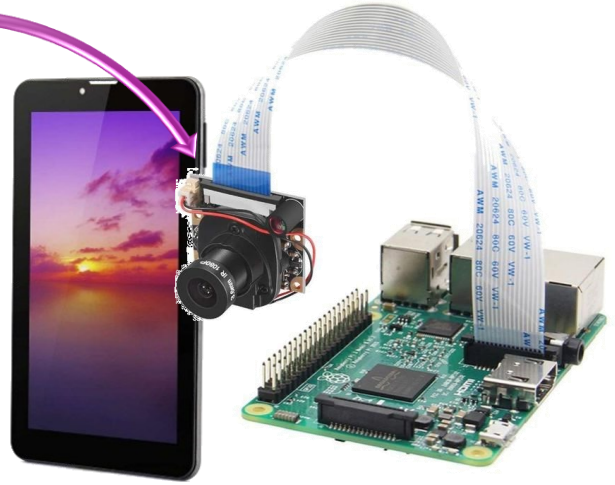
TensorFlow

PyTorch

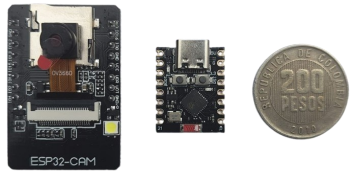
Creación Modelo

Conversión

- Conversión a TFLite
- Cuantización INT8/INT4



LiteRT



LiteRT Micro

ESPRESSIF

ESP-DL

Despliegue

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO

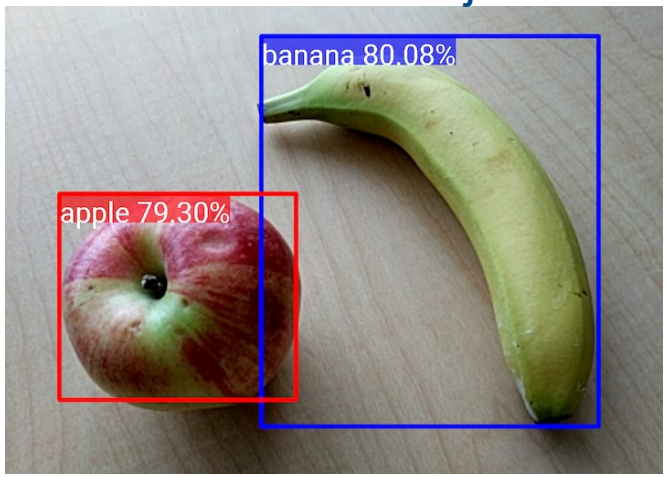
VIGILADA MINEDUCACIÓN - SNIES 9943

Aplicaciones soportadas en LiteRT (https://developers.google.com/edge/litert)

1. Clasificación de imágenes
2. Detección de objetos
3. Reconocimiento de voz
4. Segmentación
5. Procesamiento natural de lenguaje
6. GenAI y asistentes …



Detección de objetos





UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Creación y entrenamiento de modelos

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

CUMBRE DIVISIONES DE ARQUITECTURA E INGENIERÍAS Y CIENCIAS JURÍDICAS

UNIVERSIDAD DEL QUINDÍO

Ejemplo 1: Creación modelo desde cero

Carpeta de Ejemplos en Colab

Ejemplo 1: Creación modelo desde cero

- Clasificación de imágenes de números manuscritos (MINST)

- Para instalar GoogleColab debe ingresar a su cuenta Google e instalar “Colaboratory” desde el Google Workspace Marketplace



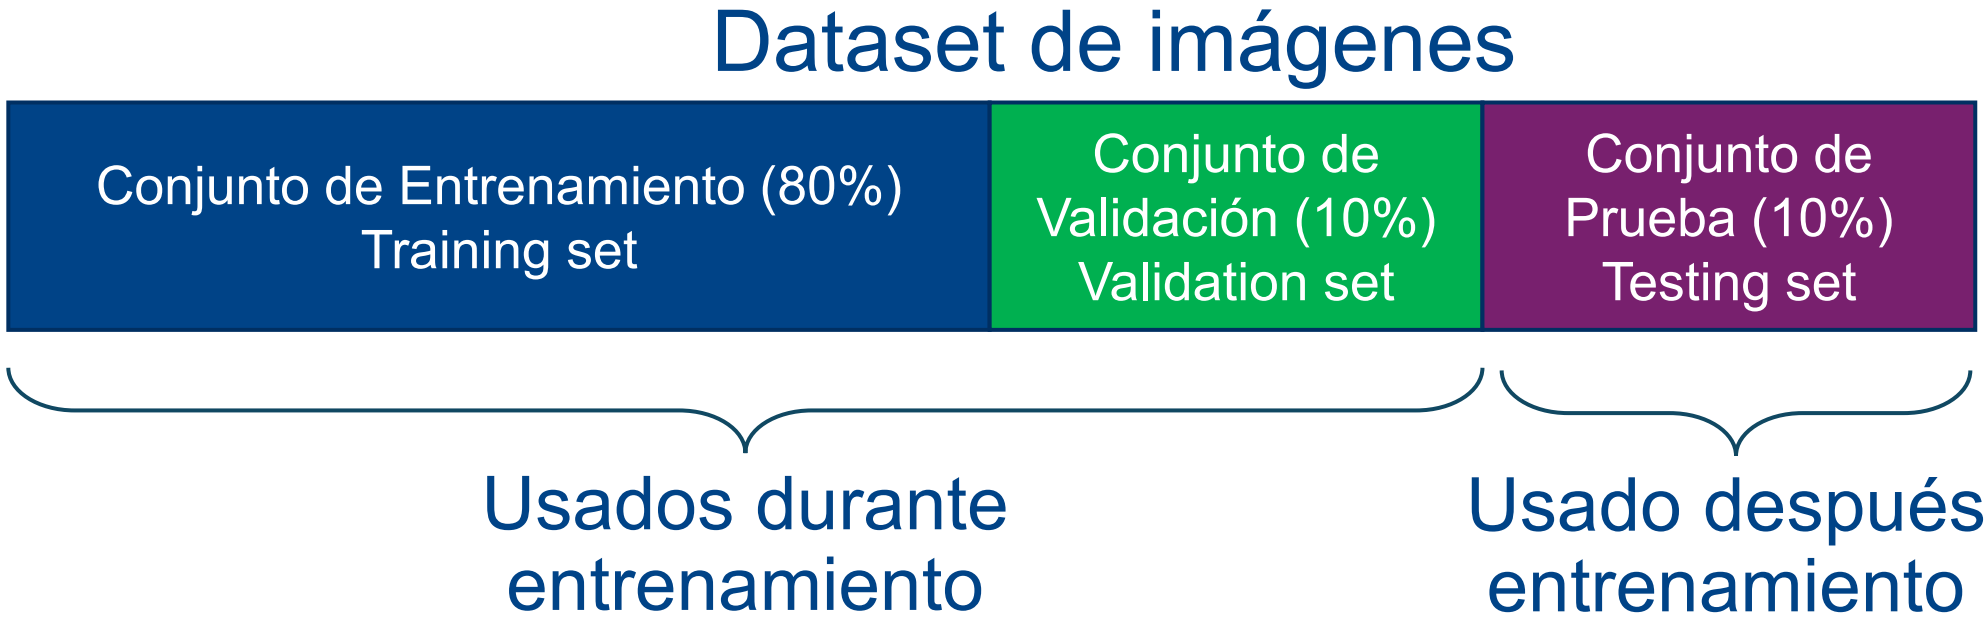
CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Consideraciones para el entrenamiento

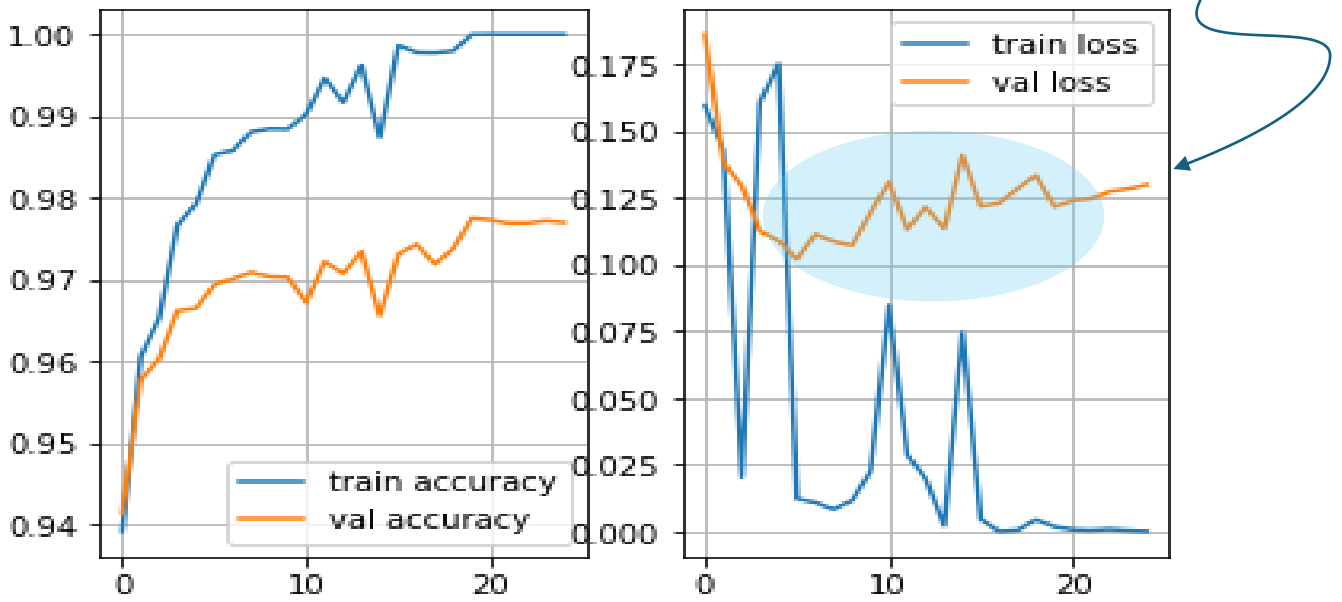
1. Particionar imágenes del dataset en 3 conjuntos



Consideraciones para el entrenamiento

2. Supervisar comportamientos precisión (accuracy) y pérdidas (loss):
   - **Accuracy**: % de error
   - **Loss**: Función que minimiza el algoritmo de entrenamiento durante el aprendizaje

Comportamiento típico de sobreajuste (overfitting)



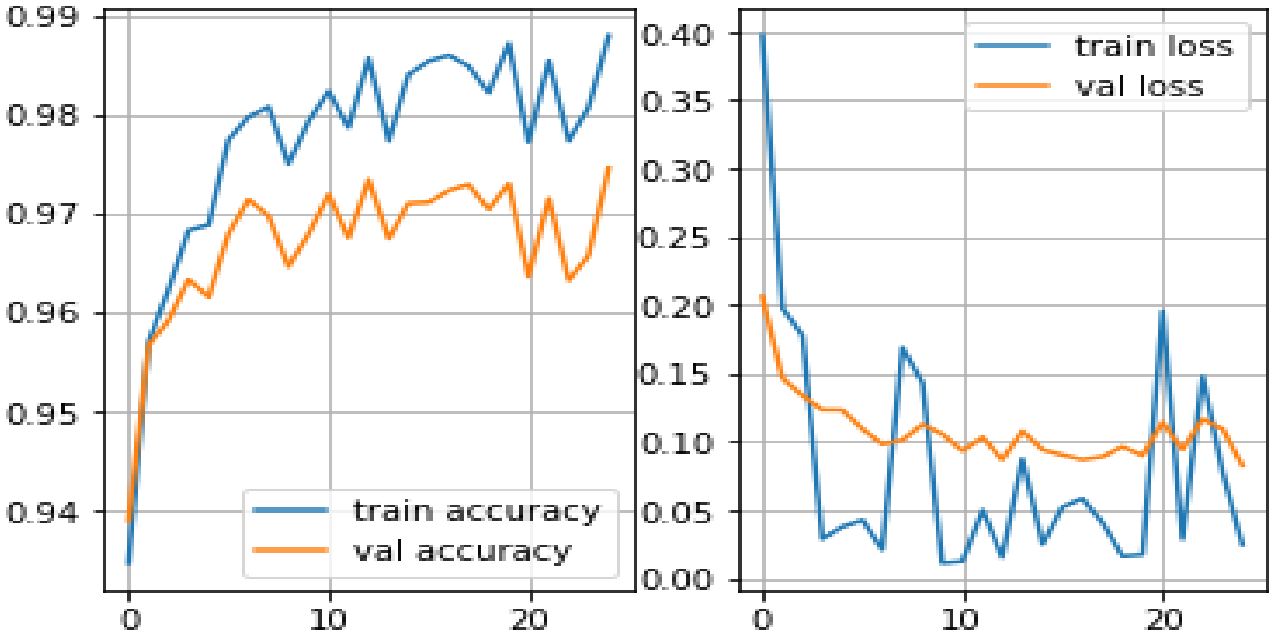
Overfitting: Cuando la red neuronal se comienza a aprender los datos.

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Consideraciones para el entrenamiento

2. Supervisar comportamientos precisión (accuracy) y pérdidas (loss):
   - **Accuracy**: % de error
   - **Loss**: Función que minimiza el algoritmo de entrenamiento durante el aprendizaje

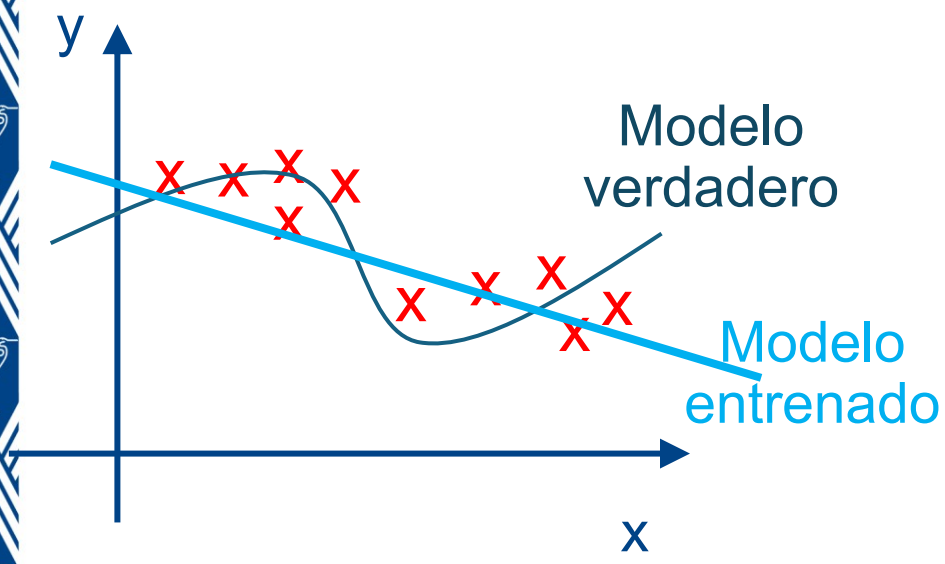
Comportamiento ideal sin overfitting



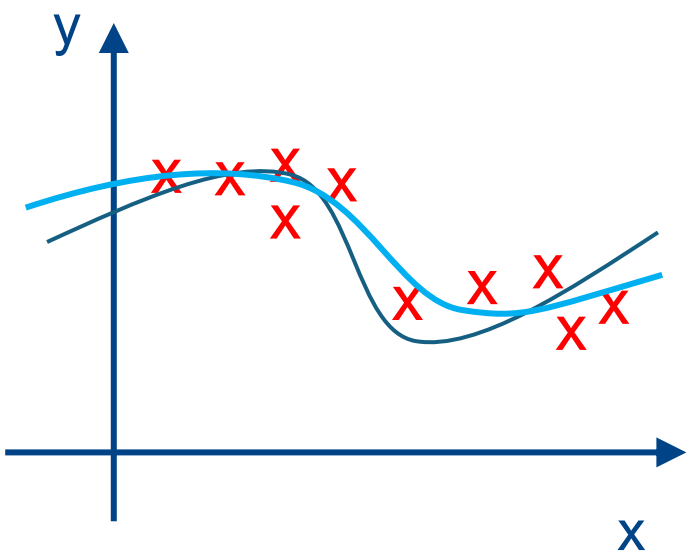
UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Consideraciones para el entrenamiento

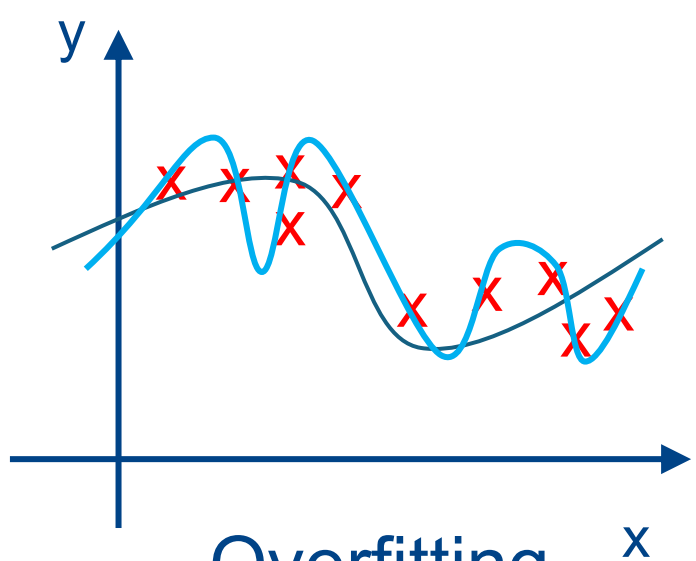
¿Por qué hay que evitar el overfitting?
La red neuronal no generaliza



Mala generalización



Buena generalización



Overfitting

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

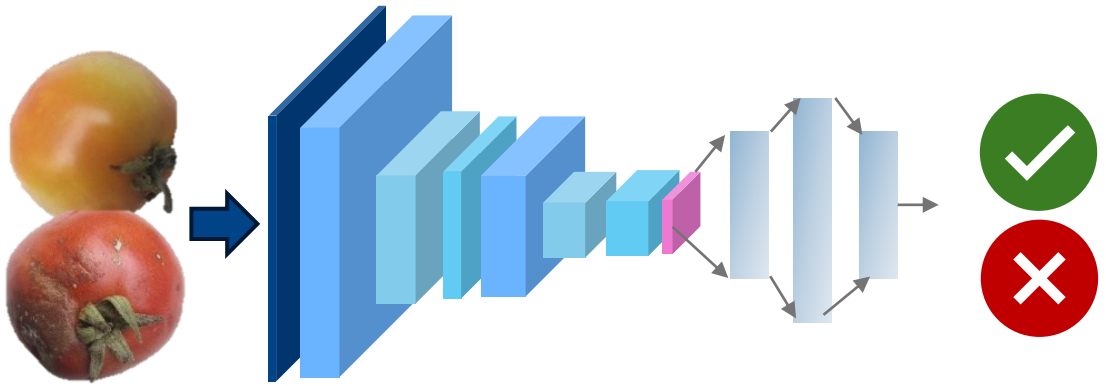
Ejemplo 1

Es tiempo de terminar la actividad para crear un modelo completo y evaluar su desempeño



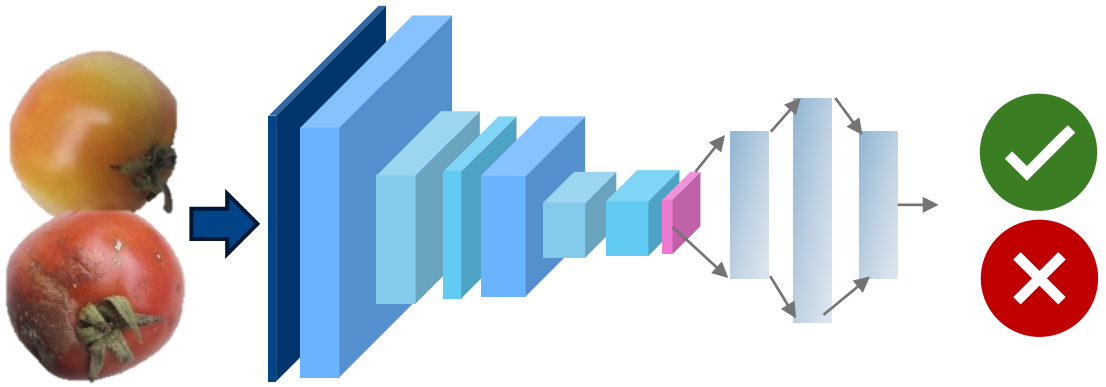
15 min

Ejemplo 2: Transferencia de aprendizaje



Implementar un sistema de clasificación de tomates en sanos y dañados

Ejemplo 2: Transferencia de aprendizaje



MobileNet v3:
Smartphones /
RaspberryPi (versión small)

EfficientNet:
Smartphones / RaspberryPi

1. Partir de un modelo pre-entrenado como MobileNet v3 small o EfficientNet y modificar la cabeza de clasificación
   - TFLite no permite hacer modificaciones significativas a la red.
2. Contar con una base de datos para reentrenar
3. Aplicar fine-tuning para reentrenar las últimas capas

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Despliegue de modelos en sistemas embebidos

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

CUMBRE DIVISIONES DE ARQUITECTURA E INGENIERÍAS Y CIENCIAS JURÍDICAS

UNIVERSIDAD DEL QUINDÍO

Despliegue de modelos

TensorFlow

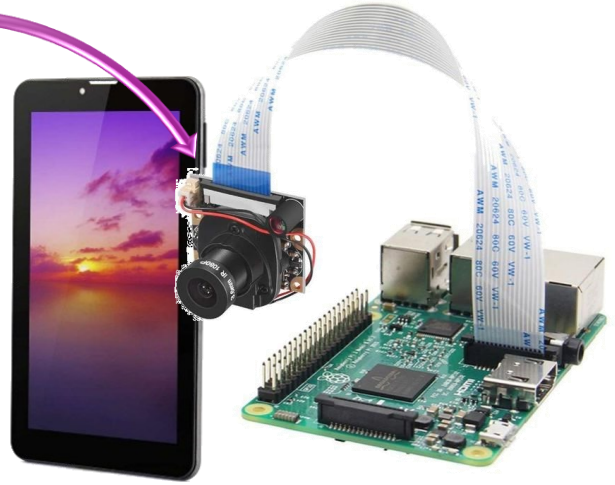
PyTorch

Creación Modelo

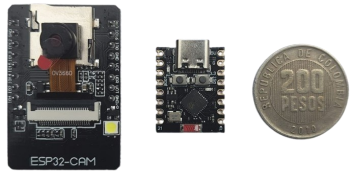
Conversión

- Conversión a TFLite
- Cuantización INT8/INT4

¿?



LiteRT



LiteRT Micro

ESPRESSIF

ESP-DL

Despliegue

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO

VIGILADA MINEDUCACIÓN - SNIES 9943

Conversión a TFLite

Alternativa 1: Exportar el modelo a formato FLOAT32:

```
converter = tf.lite.TFLiteConverter.from_keras_model(model)
tflite_model = converter.convert()
with open("clasificador_tomates_v1.tflite", "wb") as f:
    f.write(tflite_model)
```

Se puede verificar el modelo en https://netron.app/

Alternativa 2: Exportar el modelo a formato INT8:

- Requiere un conjunto de calibración

> Exporta el modelo a un formato TFLite que sea compatible con Tensorflow Lite Micro empleando cuantización INT8

Despliegue en RaspberryPi

1) Instalar TensorFlow Lite Runtime.
   En el shell de la Rpi:

```
pip install tflite-runtime
```

2) Copiar el archivo modelo.tflite en la memoria SD

3) Crear un aplicación en Python para procesar las imágenes/señales e llamar el motor de inferencia



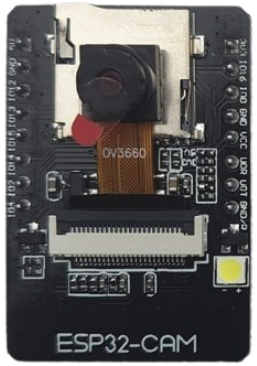
Despliegue en RaspberryPi

```
import numpy as np
from tflite_runtime.interpreter import Interpreter
# Carga modelo
interpreter = Interpreter(model_path="modelo.tflite")
interpreter.allocate_tensors()
# Información de entradas y salidas
input_details = interpreter.get_input_details()
output_details = interpreter.get_output_details()
# Crear tensor de entrada de prueba
input_shape = input_details[0]['shape’]
input_data = np.zeros(input_shape, dtype=input_details[0]['dtype’])
interpreter.set_tensor(input_details[0]['index’], input_data)
interpreter.invoke()
```

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS
UNIVERSIDAD DEL QUINDÍO
UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO VIGILADA MINEDUCACIÓN - SNIES 9943

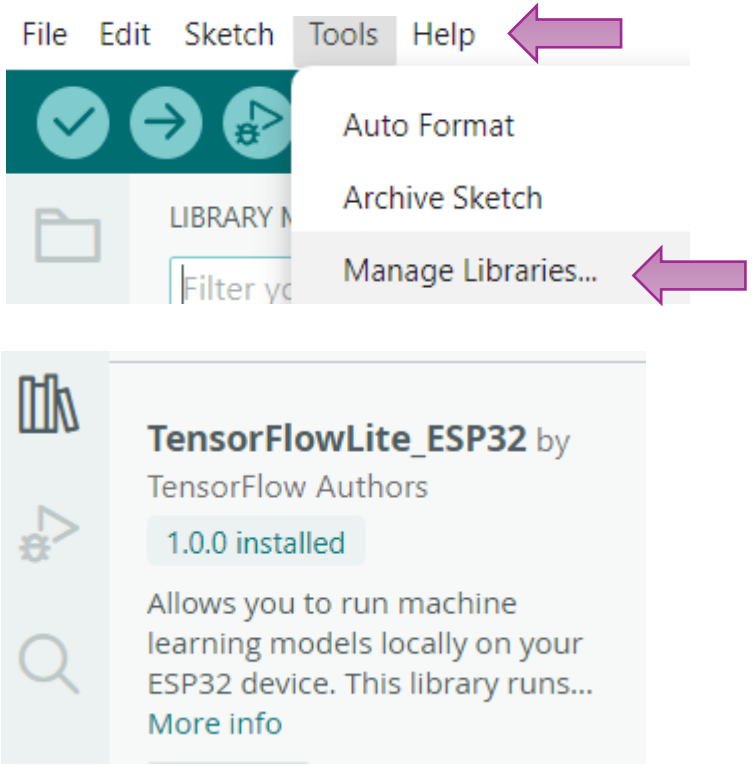
Despliegue en ESP32

1) En el entorno Arduino IDE, instalar TensorFlowLite_ESP32









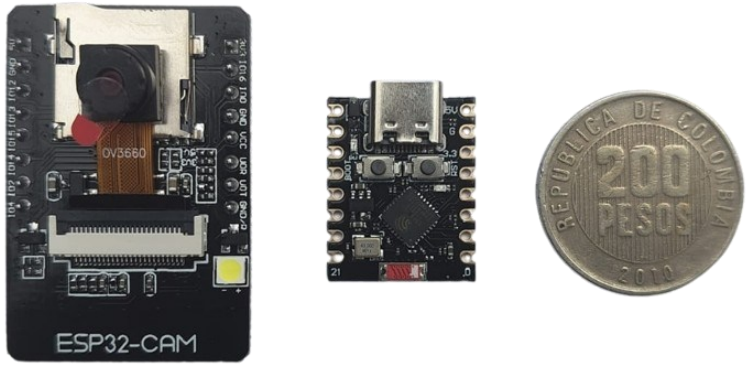
Despliegue en ESP32

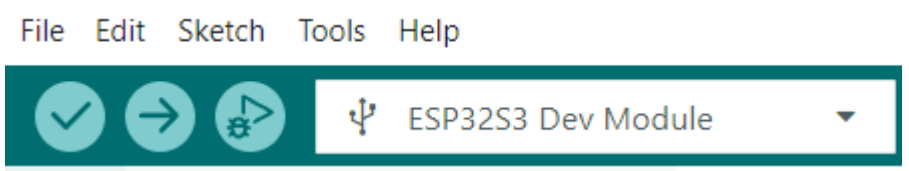
2) Usar modelo `tflite` cuantizado en INT8

3) Convertir el modelo `tflite` en un archivo de cabecera `.h` (usar la función del cuaderno `despliegue.ipynb`

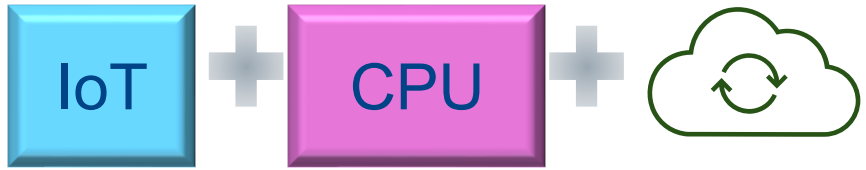
4) En el entorno Arduino IDE usar el ejemplo `esp32cam_clasificador.ino` y el archivo de cabera creado.

5) Seleccione modulo ESP32S3 y compile

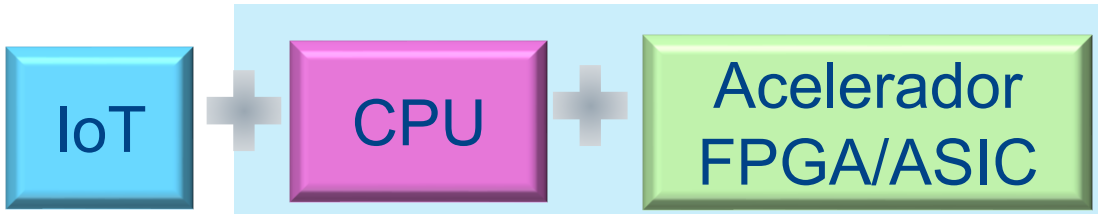




Enfoque EdgeAI



- Toda la inferencia en la nube
- Cálculo de primeras capas en el borde > Inferencia en la nube



- Simplificación de modelos
- Acelerador en FPGA o ASIC
- Técnicas avanzadas en FPGA/ASIC permiten reducir consumo energético

CUMBRE DIVISIONES DE ARQUITECTURA INGENIERIAS Y CIENCIAS JURIDICAS

UNIVERSIDAD DEL QUINDÍO

UNIVERSIDAD SANTO TOMÁS VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

Despliegue en ESP32

No todos los modelos se pueden desplegar en ESP32:

- Tamaño de pesos excede la Flash
- Tamaño de la memoria de trabajo (Tensor Arena) excede la SRAM disponible

Solución:

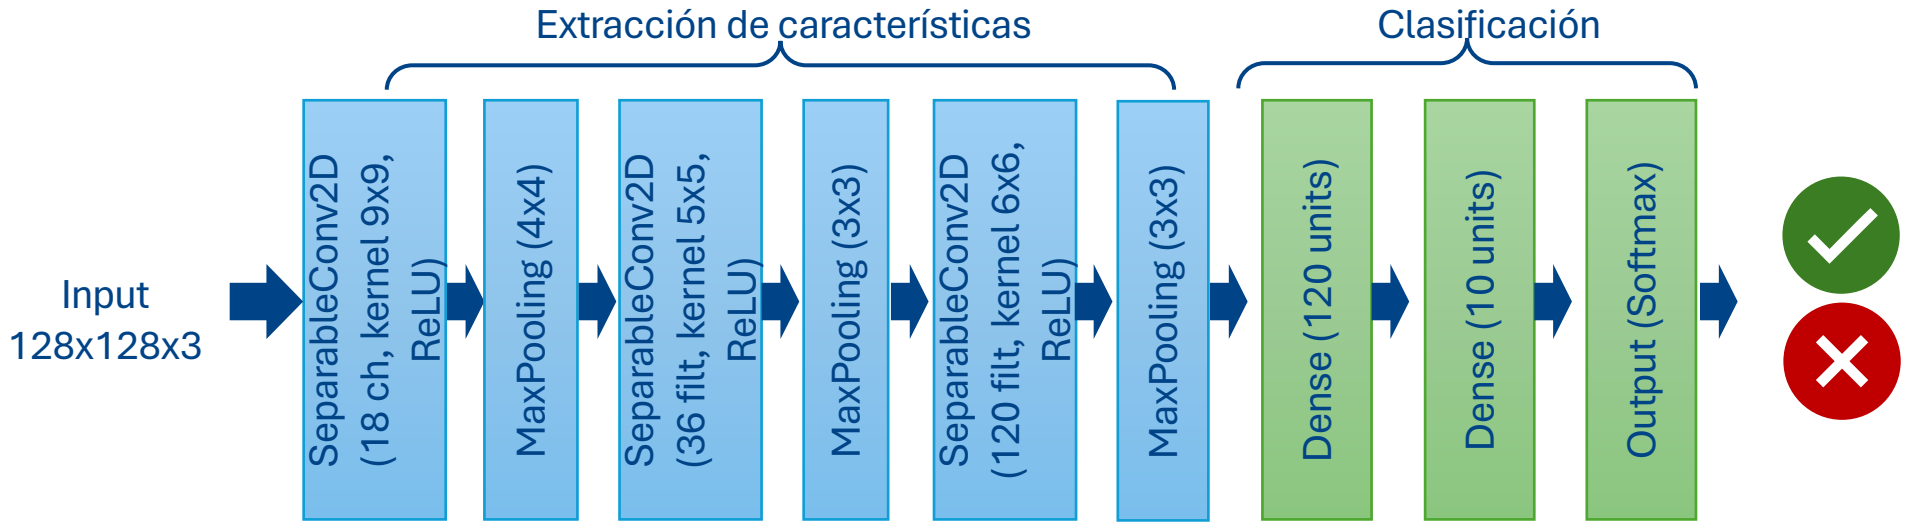
- Aplicar algoritmos de poda, compresión o rediseñar el modelo

Ejemplo 3: Simplificación de modelos

Implementar un sistema de clasificación de tomates en sanos y dañados

Modelo MinTomatoNet (Sanida & Dasygenis, 2024)





¡Muchas gracias!

Contacto:
jorgemarin@uniquindio.edu.co

UNIVERSIDAD SANTO TOMÁS
VILLAVICENCIO
VIGILADA MINEDUCACIÓN - SNIES 9943

ACREDITACIÓN INSTITUCIONAL MULTICAMPUS
DE ALTA CALIDAD POR 8 AÑOS
Resolución 014525 del 28 de Julio de 2022